

第一章 信息论与编码理论概述

李丽香

北京邮电大学网络空间安全学院

编码机制

- **编码**：信息从一种形式或格式转换为另一种形式的过程。
- **编码机制**：用预先规定的方法将文字、数字或其它对象编成数码，或将信息、数据转换成规定的电脉冲信号。

信源编码

- **目的**：提高通信的有效性，即以更少的符号来表示原始消息
- **设计机制**：根据消息符号序列的统计特性来设计各种方法，把消息序列变换为较短的码字序列，同时又能保证无失真地恢复原来的消息序列
- 简而言之，就是通过减少消息符号序列中的冗余度，提高平均信息量
- 信源编码就是通常所说的数据压缩

随机错误

- **随机错误**：接收序列中的传输错误是随机出现的。
- **随机错误信道**：这样的信道称为随机错误信道。
- 常见于无记忆信道中，因为噪声随机独立地影响每个传输信号。
- 深空通信和卫星通信信道都是典型的随机错误信道。

突发错误

- 由于噪声和干扰或读写头接触不良所引起的错误，往往不是随机错误，而是成群成串出现的错误。
- **突发错误**：不同状态特性下，错误出现的概率不一样，这种错误为突发错误。
- 突发错误的例子：无线通信(由多径传输引起的信号衰落造成的错误)，有线和电缆传输(开关脉冲和串话的影响)，磁带记录(涂层缺损和灰尘引起的带脱落)。
- **突发错误信道**：由于信道状态特性变化较大，进而有突发错误信道的概念。这种产生比较密集错误的信道称为突发错误信道或者有记忆信道。
- 突发错误常出现在有记忆信道中，此时噪声对各次传输的影响是彼此相关的。

纠错码

- **目的**：检测和纠正由于非人为(自然)因素引起的传输错误。
- 即提高通信的可靠性
- 纠错编码主要用于实现信道纠错，又叫做信道编码或者差错控制编码。
- **设计机制**：通过对消息符号序列加入冗余信息，使得接收方收到信号后，可以通过这些冗余信息进行检错和纠错
- 本课程主要讲述各种纠错码

纠错码的分类

- **纠随机错误码**：为纠正随机错误而设计的码称为纠随机错误码。
- **纠突发错误码**：为纠正突发错误而设计的码称为纠突发错误码。

数字通信系统模型

所有的数字通信系统，如雷达、遥控遥测、数字存储系统、计算机等，都可以归结为下图所示的模型：




图1 数字通信(传输)系统模型

数字通信系统的简化模型

编码理论关注的是信道编码器和信道译码器。为集中考虑信道编码与译码，将图1的模型简化为：




图2 简化的数字通信系统模型

$$\begin{cases} U = [u_1, u_2, \dots, u_K] \\ V = [v_1, v_2, \dots, v_K] \end{cases} \quad \begin{cases} u_k \in U = \{a_1, a_2, \dots, a_Q\} \\ v_k \in V = \{a_1, a_2, \dots, a_Q\} \end{cases}$$

$$\begin{cases} X = [x_1, x_2, \dots, x_N] \\ Y = [y_1, y_2, \dots, y_N] \end{cases} \quad \begin{cases} k = 1, 2, \dots, K \\ n = 1, 2, \dots, N \end{cases}$$

信道模型

设计通信系统的关键问题之一：如何解决可靠性和有效性(快速性)这对矛盾？




图3 信道模型

$$\begin{cases} Y = [y_1, y_2, \dots, y_N] \\ X = [x_1, x_2, \dots, x_N] \end{cases} \quad \begin{cases} k = 1, 2, \dots, K \\ n = 1, 2, \dots, N \end{cases}$$

无记忆信道和有记忆信道

无记忆信道：如果在给定时间间隔上，检测器的输出只与在该时间间隔上传送的信号有关，而与任何前面时间的传送的信号无关，称此信道为无记忆信道。该信道可以用如下公式表示：

$$P(Y / X) = \prod_n p(y_n / x_n)$$

有记忆信道：一种M元输入、Q元输出的信道模型。该信道可以用如下公式表示：

$$P(y_n / x_{n-K+1}, \dots, x_{n-1}, x_n)$$

离散无记忆(DMC)信道

是一种M元输入、Q元输出的信道模型。

条件概率P(Y|X)是描述该信道的最好方式，也叫做转移概率，其中X表示调制器输入符号，Y表示解调器输出符号，P(Y|X)表示发送为X接收为Y的概率。




图4 二元输入Q元输出的离散无记忆信道模型

二元对称(BSC)信道




图5 二元对称信道模型

信道矩阵：一个信道也可由它的转移概率组成的矩阵来表示。

信道矩阵

一般离散单符号信道的信道矩阵为：

$$\begin{matrix} & \begin{matrix} b_1 & b_2 & \cdots & b_s \end{matrix} \\ \begin{matrix} a_1 \\ a_2 \\ \vdots \\ a_r \end{matrix} & \begin{bmatrix} P(b_1|a_1) & P(b_2|a_1) & \cdots & P(b_s|a_1) \\ P(b_1|a_2) & P(b_2|a_2) & \cdots & P(b_s|a_2) \\ \vdots & \vdots & \ddots & \vdots \\ P(b_1|a_r) & P(b_2|a_r) & \cdots & P(b_s|a_r) \end{bmatrix} \end{matrix}$$

加性高斯白噪声(AWGN)信道

- **加性噪声：**叠加在信号上的一种噪声。
- **白噪声：**噪声的功率谱密度在所有的频率上均为一常数。
- **高斯白噪声：**白噪声取值的概率分布服从高斯分布，其自相关系数为无延时的冲击函数。




图6 AWGN信道模型

《编码理论》课程

第二章 信息论基础与信源编码理论

李丽香

北京邮电大学网络空间安全学院

信息的概念

- 1948年，仙农发表了一篇重要的论文《通信的数学理论》，对信息作了科学的定义。
- 先请读几个句子：
 - 明天，太阳从东方升起。
 - 电话铃声将会在一个小时之内响。
 - 这个冬天，哈尔滨将下雨。
- 一个句子中所含信息的多少，同句子中所表达的事件出现的概率有关，呈现相反的关系。
- 仙农对于**信息的定义**：**信息是事物运动状态或存在方式不确定性的描述。**

自信息

- **定义：**考虑离散随机变量X，其样本空间为{x_i, i=1, 2,...,n}，则事件X=x_i的自信息的定义为
$$I(x_i) = \log\left(\frac{1}{P(x_i)}\right) = -\log P(x_i)$$
- 自信息的单位由对数的底来决定，以2为底，单位就是比特(bits)，以e为底就是奈特(nats)。自信息非负。

例子：考虑一个可以同时输出2个比特的离散无记忆的信源C。该信源有4种可能的输出{00, 01, 10, 11}，其中每一种可能的输出都是独立不相关的，其出现的概率为P(C)=0.25。因此，信源C的每个可能的输出的自信息为
 $I(C) = -\log_2 P(x_i) = -\log_2 0.25 = 2\text{bits}$

条件自信息

• **定义：** 在给定 $Y=y_i$ 的情况下，考虑离散随机变量 X ，其样本空间为 $\{x_i, i=1, 2, \dots, n\}$ ，则事件 $X=x_i$ 的条件自信息量的定义为

$$I(x_i|y_i) = \log\left(\frac{1}{P(x_i|y_i)}\right) = -\log P(x_i|y_i)$$

其中， $P(x_i|y_i)$ 是 x_i 的条件概率，也称为后验概率。 $P(x_i)$ 称为先验概率。

• 条件自信息量非负。

互信息

• **定义：** x_i 和 y_i 之间的互信息定义为 $I(x_i; y_i) = \log\left(\frac{P(x_i|y_i)}{P(x_i)}\right)$

• 互信息的性质：

- 性质1：互易性 $I(x_i; y_i) = I(y_i; x_i)$ 。
- 性质2：当 x_i 和 y_i 是统计上独立的，即 $P(x_i|y_i) = P(x_i)$ ，则 $I(x_i; y_i) = 0$ 。
- 性质3：互信息量可以是正的，也可以是负的。

思考题：计算二元对称(BSC)信道的互信息量？

平均自信息量(信息熵)

• **定义：** 离散随机变量 X 的平均自信息定义为，其样本空间为 $\{x_i, i=1, 2, \dots, n\}$ ，则事件 $X=x_i$ 的平均自信息量的定义为

$$H(X) = E\left[\log\left(\frac{1}{P(x_i)}\right)\right] = \sum_{i=1}^n P(x_i) I(x_i) = -\sum_{i=1}^n P(x_i) \log P(x_i)$$

其中 $H(X)$ 表示每个信源符号的平均信息量。

例子：变量 X ， $P(X=x_1)=0.99$ ， $P(X=x_2)=0.01$ ，变量 Y ， $P(Y=y_1)=0.5$ ， $P(Y=y_2)=0.5$ ，则信息熵为 $H(X)=-0.99\log0.99-0.01\log0.01=0.08$ (比特/符号)， $H(Y)=-0.5\log0.5-0.5\log0.5=1$ (比特/符号)。

平均条件自信息量(条件熵)

• **定义：** 平均条件自信息 $H(X|Y)$ 定义为

$$H(X|Y) = \sum_{i=1}^n \sum_{j=1}^m P(x_i, y_j) \log \frac{1}{P(x_i|y_j)}$$

思考题：计算二元对称(BSC)信道的平均条件自信息量(条件熵)？

等长信源编码定理

• **定理：** 一个熵为 $H(X)$ 的离散无记忆信源，若对信源长为 N 的符号序列进行等长编码，设码字是从 r 个字母的码符号集合中，选取 l 个码元组成。对于任意的 $\epsilon > 0$ ，只要满足

$$\frac{l}{N} \geq \frac{H(X) + \epsilon}{\log r}$$

则当 N 足够大时，可实现几乎无失真编码，即译码错误概率可为任意小。

变长码

表1 译码不唯一的变长码例子

字母	码字	字母	码字
A	0	E	10
B	1	F	11
C	00	G	000
D	01	H	111

- 若对字母序列 ABADCB 进行编码，则得到 0 1 0 01 00 0 1
- **译码不唯一：** 可能被译为 DADAAAB(01 0 01 0 0 0 1) 或者 AEDGB(0 10 01 000 1)

注：变长码必须是惟一可译码，才能实现无失真编码。

变长信源编码定理

- **定理**: 一个熵为 $H(X)$ 的离散无记忆信源, 并有 r 个码元的码符号集合, 总可以找到一种无失真编码方法, 构成惟一可译码, 使其平均码长满足

$$\frac{H(X)}{\log r} \leq \bar{L} < \frac{H(X)}{\log r} + 1$$

则当 N 足够大时, 可实现几乎无失真编码, 即译码错误概率可为任意小。

信道的信息传输率

- 变长信源编码定理中的极限值 $H(X)/\log r$ 同等长信源编码定理中的极限值是一致的。

• **定义**: 信道的信息传输率(码率)为 $R = \frac{H(X)}{\log r}$

- 因为 $\bar{L} \geq H(X)/\log r$, 所以得到编码后信道的信息传输率为 $R \leq \bar{L}$

信源编码—霍夫曼(Huffman)编码

- 一个离散无记忆信源有 7 个符号 $x_i, i=1, \dots, 7$, $P(X=x_1)=0.37, P(X=x_2)=0.33, P(X=x_3)=0.16, P(X=x_4)=0.07, P(X=x_5)=0.04, P(X=x_6)=0.02, P(X=x_7)=0.01$, 将 7 个信源符号按照概率递减的顺序进行排序, 构造如图 8 所示的霍夫曼树。
- 按照编码路径从后往前返回, 就得到对应的码字 $x_7=1111111, x_6=1111110, x_5=111110, x_4=1110, x_3=110, x_2=10, x_1=0$ 。




图8 霍夫曼树

思考题: 如何编程序实现霍夫曼编码?

游程编码

- **游程**: 信源输出的字符序列中, 各种字符连续的重复出现的字符串的个数。
- **游程编码**: 就是将这种字符串序列映射成字符串的长度和字符串的位置的标志序列。
- 游程编码常用作图形文件的编码方式, 如 .bmp 和 .tiff。

例子: 考虑比特序列 111111111111111100000000000000001111, 可以被表示成 (15,1),(19,0),(4,1), 字符最长的重复的数目为 19, 因此, 把该比特序列编码为 (01111,1), (10011,0), (00100,1), 此时压缩率为 18:38=1:2.11。

思考题: 如何编程序实现游程编码?

LZ(Lemple-Ziv)编码

- 分段的方法: 1) 游程先取第一个符号作为第一段, 然后再继续分段; 2) 若有出现与前面符号一样时, 就再添加紧跟后面的一个符号一起组成一段; 3) 尽可能取最少个连着的符号并保证各段都不相同; 4) 以此类推, 直至信源符号序列结束。
- 编码方法: 首先去掉最后一个符号, 然后看剩下的字符串在字典中的排序, 这个排序值转换成二进制数作为指针 x 的值, 最后一个信源符号作为码字第 2 项 d 的值, 即得到码字 (x, d) 。

例子: 考虑比特序列 10101101101101010111, 根据上面的编码方法可把该比特序列分段为 1, 0, 10, 11, 01, 101, 010, 1011。
码字为: (000,1),(000,0),(001,0), (001,1), (010,1), (011,1), (101,0), (110,1)。

思考题: 如何编程序实现 LZ 编码?

信道容量

- **定义**: 考虑某种概率分布为 $P(x)$ 的离散无记忆信源, 对于一个固定的信道, 信道容量被定义为最大的平均互信息, 此时传输每个符号平均获得的信息量最大, 即对于每个固定的信道可以达到最大的信息传输率, 即

$$C = \max_{P(x_j)} I(X; Y) = \max_{P(x_j)} \sum_{j=1}^{q-1} \sum_{i=0}^{r-1} P(x_j) P(y_i | x_j) \log \frac{P(y_i | x_j)}{P(y_i)}$$

其约束条件为 $P(x_j) \geq 0, \sum_{j=0}^{q-1} P(x_j) = 1$

思考题: 如何计算给定某种信道的信道容量?

纠错编码的理论基础

●**香农编码定理**：如果系统的传输率小于信道容量，那么适当选择编码技术就能实现可靠通信，即将差错率减小到任意小的程度。更确切地，每个信道都具有固定的信道容量 C ，对任何小于 C 的信息传输率 R ，存在一个码长为 n 码率为 R 的分组码，若用最大似然译码，则其译码错误概率为 $P_e \leq Ae^{-nK_0(R)}$ 。对于码率为 R 约束长度为 n 的卷积码，其译码错误概率也有类似的关系，即 $P_e \leq Be^{-nK_0(R)}$ ，其中 A 和 B 都为大于0的数， $E_b(R)$ 和 $E_c(R)$ 为正实函数，叫做误差指数。

31

科学哲学：过程比结果更重要(课堂思政)

- 香农编码定理解决了纠错码的存在性问题，虽然仙农当时未能构造出一个纠错码，但是从此之后纠错编码的研究与应用开始了前所未有的发展，人们一直在不停的努力解决构造性问题。为了接近信息传输率的上限，已经提出了很多的纠错编码技术。
- 我们从香农(1916-2001)生平故事中得到一个启示：富有创造性的富有成果的生活也可以是快乐的生活。

科学哲学家 史蒂文·文森特·普莱斯——一个真正的科学哲学家。



2016年11月11日，普莱斯作为加拿大皇家学会成员，在加拿大蒙特利尔去世。他于1916年出生于英国，是一个物理学家、哲学家、科学史学家。普莱斯在科学哲学领域做出了重要贡献，特别是在科学革命和科学进步方面。他的著作《科学革命的结构》和《科学进步》是科学哲学领域的经典之作。

仙农的主要贡献：香农定理



2016年11月11日，仙农在马里兰州去世。仙农是美国著名的数学家、工程师、物理学家。他在信息论领域做出了开创性的贡献，提出了香农定理，奠定了现代信息论的基础。他的著作《通信的数学原理》是信息论领域的经典之作。

32

信道编码定理

●**定理**：假设DMS有信源字符集 X ，熵为每信源符号 $H(X)$ 比特，而且信源每 T_s 秒产生一个符号，那么信源的平均信息率为每秒 $H(X)/T_s$ 比特，假设信道可以每 T_c 秒使用一次，而信道容量为每次信道使用 C 比特，那么每单位时间的信道容量为每秒钟 C/T_c 比特。如果 $H(X)/T_s \leq C/T_c$ ，那么就存在编码方案使得在有噪声的信道上传输的信源消息，能够以任意小的错误概率进行恢复。

例子：考虑BSC信道，信道容量 $C=1+p\log 2p+(1-p)\log 2(1-p)$ ，如果转移概率 $p=10^{-2}$ ，则可计算出 $C=0.919$ ，那么就可以知道肯定存在信息传输率为 $r<0.919$ 的编码方案，使得信息可以在有噪声的信道上传输的信源消息，能够以任意小的错误概率进行恢复。

33