

人工智能安全发展研究

王昱

(山东省互联网违法和不良信息举报中心, 山东 济南 250000)

【摘要】人工智能作为当今科技领域的热点之一,正在以前所未有的速度迅猛发展,并在各个领域得到广泛应用,深刻改变着人类社会的方方面面。然而,随着人工智能技术的普及和应用,人们越来越关注其带来的安全问题。从数据隐私泄露到算法歧视,从安全漏洞到人工智能对社会的潜在影响,人工智能安全问题日益成为各界关注的焦点。基于此,本文将从技术、法律、政策、伦理等多个层面出发探讨如何推动人工智能安全发展。

【关键词】人工智能;安全;发展

【中图分类号】TP18 **【文献标识码】**A **【DOI】**10.3969/j.issn.1672-2396.2023.05.003 **【文章编号】**16722396[2023]67-0007-03

Research on Artificial Intelligence Security Development

WANG Yu

(Shandong Internet Illegal and Bad Information Reporting Center, Jinan Shandong 250000, China)

Abstract: As one of the hot spots in the field of science and technology, artificial intelligence is developing rapidly and rapidly at an unprecedented speed, and is widely used in various fields, profoundly changing all aspects of human society. However, with the popularization and application of artificial intelligence technology, people are paying more and more attention to the security problems it brings. From data privacy breaches to algorithmic discrimination, from security vulnerabilities to the potential impact of artificial intelligence on society, AI security issues have increasingly become the focus of attention. Based on this, this paper will discuss how to promote the safe development of artificial intelligence from multiple aspects such as technology, law, policy and ethics.

Key words: Artificial Intelligence; secure; develop

0 引言

在数字化浪潮的推动下,人工智能技术正在成为引领社会发展的关键引擎。AI技术以其强大的计算和学习能力为人类带来了前所未有的效率和便利。然而,这种强大的技术力量也带来了一系列前所未有的安全挑战^[1]。针对这些安全挑战,技术、法律与政策、伦理及国际合作等多方面的努力显得尤为重要。

1 技术层面的推动

1.1 加强安全技术研究和创新

人工智能系统的持续发展离不开其安全性能的保障。为增强人工智能系统的稳定性和防御性,相关人员必须提升安全科技探索与革新能力。一是探索安全策略与数值模型。针对目前人工智能

系统中的安全薄弱环节与攻击途径,相关人员应进行深度探索,如探索具有较强鲁棒性的对抗性攻击方法,构建稳定高效的算法与模型,以抵御入侵威胁。二是开发鲁棒性机器学习算法抵御攻击。针对人工智能系统在应对对抗性攻击时的敏感性,相关人员应探索并打造合理的机器学习策略,创新损失函数设计、算法优化及网络架构调整,以使模型能有效抵抗各类侵袭,进一步优化人工智能系统的抗干扰功能。三是促进隐私保护技术创新。随着数据的广泛运用,隐私保护技术的研究与运用亟待加强,只有综合运用差分隐私和同态加密等手段,才能确保用户隐私信息不被恶意使用和泄露。

1.2 构建可信赖的数据基础

人工智能技术的培训与验证离不开海量的数

据支持,因此,打造可靠的数据基石对于保障人工智能平台的安全至关重要。相关人员可从以下几个方面入手。一是构建大规模和高品质的数据集。创建大规模和高品质的数据集对于 AI 系统的训练与评估具有关键意义。这些数据集必须涵盖各种类型的样本,确保数据的全面性,以增强 AI 系统的普适性和稳定性。二是确保数据精准、稳定且安全。在信息搜集与处理环节,务必保证数据的精确性、稳定性和安全性。三是促进隐私保护技术运用。为防止用户隐私信息被恶意使用和泄露,相关人员应促进隐私保护技术的使用。

1.3 提高算法透明度和解释性

人工智能设备的决策路径常常被看作是“神秘黑盒”,透明度不足及解释欠佳,对安全性和信任度构成威胁。因此,增强人工智能系统的安全性,需重视算法透明度和解释性的提高。在具体实践中,相关人员可从以下几点入手。一是加大对算法说明的探究力度,探索人工智能算法的可解释性。相关人员可以针对各类人工智能算法进行阐释性分析,剖析其决策逻辑与特性,使用户掌握其系统运作机理。二是创造可视化辅助手段与方法,创新可视化策略与手段。例如,相关人员可以以图形化的方式展示人工智能系统决策流程与最终效果,协助用户掌握人工智能技术的运作机制及内在逻辑。三是优化算法评估与验证。在算法性能评估、鲁棒性检验及安全漏洞排查等方面,相关人员需评估算法的可解释性和透明度,重塑人工智能算法评估与验证,确保决策结果的精确性和稳定性。

2 法律与政策层面的推动

法律与政策对于确保人工智能安全发展至关重要。主要包括制定人工智能安全法规、加强隐私保护、促进人工智能科技的健康发展等方面^[2]。

2.1 制定人工智能安全法律法规

一是确定人工智能体系的责任与义务。相关法规要确定人工智能体系的责任与义务,加强对人工智能系统设计、生产、销售和使用等方面的约束与监督,明确责任承担者和构建问责制度,以确保人工智能系统开发、运行及应用的安全合规。二是严格把控人工智能系统的监督与审核。相关部门要设立人工智能安全审查机制,对涉及人工智能技术的产品和服务进行安全评估,以确保其符合安全法规要求,并能约束人工智能系统的行为,迅速识别并解决潜在危险和难题。三是约束人工智能领域数据采集与运用。相关法律法规要约束个

人数据采集、保存及运用,确定个人数据的产权和管控权,以确保数据获取合法合规、数据应用合理适当。

2.2 加强隐私保护

一是制定个人数据保护法律法规,加强对个人数据的保护。个人数据保护法律法规明确要求个人数据的收集、存储、处理和传输应当符合法律法规和道德规范,以保护用户的隐私权。二是建立数据使用和共享制度。相关部门要建立数据使用和共享制度,促进数据共享和交流,加强数据的跨界流动和应用,并规范数据的使用和共享行为,借此推动数据驱动的人工智能技术发展。三是加强隐私技术的应用。相关部门要推动差分隐私、同态加密等隐私保护技术的应用,以确保用户的隐私数据不被滥用和泄露。

2.3 促进人工智能技术的健康发展

一是促进人工智能领域的发明与应用。相关部门应采取措施促进人工智能领域的创新及应用,如借助政府资金、税收减免、科技创新策略等措施来推动企业和研究机构积极投身于人工智能技术的创新与实践,从而促进人工智能领域的稳步前进。二是重塑人工智能产业的标准与规范。相关部门应重构人工智能产业的标准与规范框架,设定人工智能产品与服务的准则及规则,优化产品与服务品质并保障其安全性,同时加大对人工智能产业的监管力度,推动产业健康发展。三是促进国际联盟与合作。相关人员应重塑国际协作与沟通格局,借助国际合作机制、国际标准化组织等渠道促进全球人工智能技术的互动与协作,推动全球人工智能产业的扩张与进步。

总之,在法律与政策的推动下,政府、立法机构、监管机构等各方要齐心协力,为人工智能的安全和进步提供制度维护与政策扶持。

3 伦理层面的推动

3.1 建立人工智能伦理框架

一是设定人工智能道德准则与标准。一方面,相关部门要设定尊重人权、维护隐私、公平对待、公正行事、透明操作及可解释性等方面的智能科技道德规范;另一方面,相关部门要设定智能科技道德准则,确立人工智能技术的道义规范与价值导向,确保人工智能发展符合道义规范。二是突出人工智能技术在社会责任感方面的作用。相关部门要明确人工智能领域从业者和研究者的道义担当,强调人工智能技术的社会效益及正面作用,以促使他

们在开发和应用人工智能技术时关注社会效应和道德风险。

3.2 加强人工智能伦理教育

一是促进人工智能道德素养的传播。相关部门要借助教育机构和媒体等途径传播AI道德观念,同时加强人工智能道德观念的普及与教导,以提高民众对人工智能道德问题的敏感度、认知水平和防范能力。二是培育人工智能领域从业者的道德担当。在人工智能领域的教学过程中,教师应采用课程安排、实例剖析、研讨等形式带动学生探讨人工智能伦理方面的议题,塑造健全的道德观念与行为准则,同时重塑伦理责任意识和导向,强化AI领域从业者的道德品质与公共担当。

3.3 推动人工智能伦理研究

一是加强人工智能道德探讨。研究人员要关注人工智能道德领域,探讨人工智能对道德观念、社会公平及人类尊严等伦理方面的影响,审视人工智能伦理约束与发展底线,提出伦理准则与应对策略。二是注重人工智能道德评估与监管。相关部门要构建人工智能道德评估与监管体系,对人工智能领域的项目和产品进行伦理监控与审查,强化预防措施,迅速识别并处理伦理难题,以确保其遵循道德规范与正向社会价值观^[1]。

3.4 引导人工智能健康发展

相关部门要提倡“以人为本”的人工智能发展。一是突出人工智能发展与人性关怀的紧密结合,以及人工智能技术在社会 responsibility 方面的贡献,优先考虑人类福祉和利益,以促进人工智能领域的稳步发展,并确保人工智能技术遵循人类价值观与道德规范。二是敦促人工智能领域的从业者和研究者关注道德担当,将人工智能科技纳入人类福祉领域,推动社会持续繁荣。三是强调人工智能科技的公正、透明及肩负的社会责任,确保AI技术进步契合社会全体福祉及远景规划。

4 国际合作与信息共享

4.1 加强国际合作

一是构建全球人工智能安全联盟。各国政府与国际组织应携手打造全球人工智能安全联盟,组建特定的工作团队或部门,以推动国际协作与沟

通,并定期举办国际会议、研讨会、论坛等活动,传授经验、探讨技能、评议政策,携手应对人工智能安全问题。二是推动国际协作项目开展,联合探讨人工智能安全解决方案,促进人工智能安全进步。各国政府、企业和学术机构应携手进行人工智能安全研究,解决关键技术难题,保障人工智能系统的安全与稳定性。三是协同制定AI安全规则与准则。各国政府与国际组织应协同制定AI安全准则,整合安全规范和标准,设立全球通用的AI安全规范,为全球人工智能技术应用提供安全保障,促进全球人工智能领域稳定发展。

4.2 建立信息共享机制

一是创立全球人工智能安全数据交换中心。通过构建全球人工智能安全数据交换中心,各国政府、企业及学术界可针对安全漏洞与袭击事件实时交流安全防护策略及技术心得,监控与预防人工智能安全风险。二是推动情报互通与协作。通过设立数据互通平台,各国政府和组织可加强全球信息共享与协作,共同应对人工智能安全问题。各国政府和组织可签署协作协议,构建沟通与合作平台,重塑协作机制,以实时传递人工智能安全相关信息,共保人工智能安全稳健发展。三是重塑全球人工智能安全治理框架。各国政府与国际组织需协同构建全球人工智能安全管控体系,设立跨国协作框架,共同审视和解决全球人工智能安全问题。

5 总结

飞速进步的人工智能技术给人类社会带来了深刻的影响及无限可能,也带来了各类安全问题与挑战。各方应当齐心协力,确保人工智能领域的安全和进步。技术领域需深化安全技术的探索与革新,打造可靠的数据基石,增强算法公开性与诠释力,保障人工智能体系的安全与稳定性。法律与政策层面的相关方须构建完善的法规和政策框架,对人工智能实施严格管控与审查,推动人工智能科技稳健进步。在伦理方面,相关部门要构建AI伦理体系,重塑人工智能道德观念,引领人工智能迈向“以人为本”的新阶段。在国际协作和信息互通方面,各国应携手应对人工智能安全挑战,构建资源共享平台,保障全球人工智能领域的安全和稳定。

参考文献

- [1] 推动人工智能健康发展(创新谈)[N]. 人民日报,2023-2-5(19).
- [2] 防范人工智能风险需加强数字规则制定[N]. 科技日报,2023-4-24(08).
- [3] 生成式人工智能应用的伦理立场与治理之道:以ChatGPT为例[N]. 法治日报,2023-2-21(11).