

人工智能安全框架研究

朱倩倩¹, 唐志敏^{2, 3*}, 王新哲^{2, 3}

1. 国家工业信息安全发展研究中心, 北京, 100040

2. 中国科学院信息工程研究所, 北京, 100097

3. 中国科学院大学网络空间安全学院, 北京, 100049

摘要: 人工智能是引领未来的战略性技术, 正在引发经济社会和生产生活的深刻变革。但随着人工智能技术在各个领域的广泛应用, 其安全问题也愈发突出, 对其自身发展应用、个人隐私、社会稳定甚至是国家安全都带来了极大的影响。因此世界各国开始重视和加强人工智能安全治理, 以规范和保障人工智能的安全发展。文章提炼人工智能安全内涵, 梳理人工智能安全趋势和范围, 并分析人工智能安全与可信赖的关系。本次研究从安全目标、安全风险、安全测评和安全保障四个维度构建人工智能安全框架, 提出人工智能安全建议, 以期为人工智能安全治理能力提升、人工智能行业健康发展助力。

关键词: 人工智能; 人工智能安全; 人工智能安全框架

Research on Artificial Intelligence Security Framework

Zhu Qianqian¹, Tang Zhimin^{2, 3*}, Wang Xinzhe^{2, 3}

1.China Industrial Control Systems Cyber Emergency Response Team, 100040

2.Institute of Information Engineering, Chinese Academy of Sciences, Beijing, 100097

3.School of Cyberspace Security, University of Chinese Academy of Sciences, Beijing, 100049

Abstract: Artificial Intelligence (AI) is a strategic technology leading the future, which is causing profound changes in economic society, production and life. However, with the wide application of artificial intelligence technology in various fields, its security problems have become increasingly prominent, which has a great impact on its own development and application, individual privacy, social stability and even national security. Countries around the world have begun to attach great importance to AI security governance, make various regulations to ensure safe and sound development of AI. The article refines the connotation of AI security, combs the trend and scope of AI security, and analyzes the relationship between intelligent security and trustworthiness. This research constructs an AI security framework from four dimensions of security objectives, security risks, security evaluation and security assurance, and proposes AI security recommendations, with a view to improving AI security governance capabilities and helping the AI industry develop healthily.

作者简介: 朱倩倩, 女, 国家工业信息安全发展研究中心工程师, 主要研究方向为人工智能安全、图像识别、自然语言处理, E-mail: zhuqianqian@cics-cert.org.cn。

通讯作者: 唐志敏, 女, 中国科学院信息工程研究所, 主要研究方向为人工智能安全、移动目标防御、网络空间欺骗, E-mail: tangzhimin@iie.ac.cn。

Keywords: Artificial Intelligence; Artificial Intelligence Security; Artificial Intelligence Security Framework

引言

2018年10月31日,习近平总书记在中共中央政治局第九次集体学习时指出,“人工智能是引领这一轮科技革命和产业变革的战略性技术”^[1]。随着人工智能技术与大数据、云计算和物联网等新兴技术不断融合与深入渗透,人工智能技术日益成为推动经济社会向智能化跃进的重要引擎。其在逐渐改变人们生产方式、生活方式和思维方式的同时,也带来一些难以预料的安全风险,给政治、经济、社会、军事等各领域带来了巨大隐患。人工智能可以赋能网络安全,为网络安全保驾护航,但也可以被恶意利用,使攻击行为的破坏力进一步增强,甚至引发新的安全风险^[2]。研究人工智能安全框架有助于更好分析和把握人工智能的风险点,为通过技术手段和管理方法消除这些风险提供支撑,助力我国人工智能产业持续健康发展。

1 人工智能安全内涵

1.1 人工智能安全趋势

人工智能的安全问题已经成为制约其快速发展和深度应用的重要因素。为保障人工智能安全,世界各国政府与区域组织纷纷成立组织,出台文件,提出人工智能发展要加强监管与测评、发展与安全并重的核心思想。其中,美国依据《2019财年国防授权法》成立了人工智能国家安全委员会,为聚合各方之力加速推进人工智能发展奠定重要基础。欧盟发布《人工智能白皮书——欧洲追求卓越和信任的策略》《欧洲议会和理事会关于制定人工智能统一规则(人工智能法)和修订某些欧盟立法的条例》等文件,对人工智能系统实行分类分级监管思想和

合规评估要求,旨在欧盟范围内规范和保障人工智能的可信应用。我国发布《新一代人工智能发展规划》《中华人民共和国国民经济和社会发展第十四个五年规划和2035年远景目标纲要》等多项政策文件,强调人工智能安全监管与评估,使人工智能安全成为未来国家战略、政府工作的重要组成部分。

1.2 人工智能安全范围

人工智能作为一项新技术,既会伴生安全问题,又会赋能安全问题^[3]。人工智能的伴生安全问题包括内生安全和衍生安全问题。人工智能安全风险指人工智能系统在设计开发、测试验证、部署应用、运行监测、重新评估、退役下线等全生命周期中面临的智能水平、可靠性、脆弱性等风险,也称人工智能技术和人工智能技术依赖系统的内生风险及人工智能系统的应用风险。

1.3 安全与可信赖的关系

2019年4月8日,欧盟委员会发布了《可信人工智能伦理准则》,为世界各国建立可信人工智能系统提供了指导方向^[4]。人工智能可信是指具体的产品或服务、数据及所用技术满足利益相关方期望且可验证的能力,通过应用不同的可信性特征对验证对象进行验证,以确保验证对象满足利益相关方期望。可信包含了安全和伦理两部分内容,因此保障人工智能安全是实现可信人工智能的必由之路。

2 人工智能安全框架

人工智能安全框架包含安全目标、安全风险、安全测评、安全保障四大维度。人工智能安

全实践分为四个核心步骤：第一步设立人视角的应用安全和系统视角的技术安全目标；第二步梳理人工智能衍生和内生安全风险；第三步测评数据、算法、基础设施和系统应用风险程度；第四步运用管理和技术相结合的方式保障安全。




图1 人工智能安全框架

2.1 安全目标

由于人工智能技术仍处于快速发展阶段，如果在设计、开发、部署、应用人工智能系统的过程中缺乏最佳实践指导，则难以提高人工智能系统安全^[5]。实践过程离不开技术和应用两个维度，因此分别提出以人为视角的应用安全目标和以系统为视角的技术安全目标。

2.1.1 人视角的应用安全

产品功能和目标的设计为系统设计和实施提供参考，是人工智能产品开发的基础性步骤，这一步骤的失误会严重损害产品呈现的最终效果。为了产品开发需要，应详细、准确考虑到各种情况，内部人员的不当使用和外部攻击者的攻击人工智能系统会给国家、社会、企业和个人带来严重危害。因此，应确保人工智能系统在设计功能时准确全面地考虑场景和突发状况，对不当使用进行适度的监管控制，对应已知和未知的外部攻击提供相应的保障机制，并符合国家法律法规和行业管理规范的要求。

2.1.2 系统视角的技术安全

人工智能系统开发、验证、部署、维护、退役的全生命周期，都存在数据、算法模型、基础设施的保密性、完整性、可控性风险^[6]。特别在

公共服务、交通驾驶^[7]、金融服务^[8]、健康卫生^[9]、福利教育等重要领域，对于生命财产安全、个人权利保障等关键事项的人工智能系统的安全要求应更为严格。因此，人工智能系统在生产实施时，应确保数据采集、传输、存储、处理、交换、销毁过程的安全，算法模型设计开发、验证测试、部署运行、维护升级、退役下线过程的安全，以承载系统为的学习框架、算力设施、云平台安全。

2.2 安全风险

随着人工智能产业的快速发展，算法黑箱^[10-11]、技术滥用、侵犯隐私^[12-13]等安全问题逐步显现，给公共安全、道德伦理、社会治理等带来挑战。主要的人工智能安全风险可以归纳为技术内生风险和系统衍生风险。

2.2.1 技术内生风险

技术内生风险主要是指人工智能系统相关的数据、算法和基础设施中蕴含的风险。其中，数据是人工智能的重要驱动，算法模型是人工智能的核心技术，基础设施是人工智能的底层支撑，相关风险可能对社会安全产生重大威胁。

(1) 数据安全风险。数据安全风险包括数据隐私^[12-13]、数据质量、数据保护安全风险。数据隐私安全风险是人工智能的开发、测试、运行过程中存在的隐私侵犯问题；数据质量安全风险是用于人工智能的训练数据集以及采集的现场数据潜在存在的质量问题，以及可能导致的后果；数据保护安全风险是人工智能开发及应用企业对持有数据的全生命周期安全保护问题。

(2) 算法安全风险。算法安全风险包括算法设计、算法黑箱和算法偏见歧视风险^[14]。算法设计安全风险是在算法或实施过程有误可产生与预期不符甚至伤害性结果；算法黑箱安全风险是基于神经网络的深度学习算法，通过复杂的计算过程对输入数据进行计算，人们难以

依据现有的科学知识和原理对输出结果加以解释;算法偏见歧视风险是在信息生产和分发过程失去客观中立的立场,影响公众对信息的客观全面认知,或者在智能决策中,通过排序、分类、关联和过滤产生不公平问题,主要表现为价格歧视、性别歧视、种族歧视^[15]。

(3) 基础设施风险。基础设施风险包括学习框架、算力设施和云平台安全风险^[15]。学习框架可细分为云端和终端两类,其中云端框架安全风险主要来自自身代码的实现以及第三方的依赖库问题;终端框架安全风险主要存在于模型网络参数、模型网络结构,以及模型转换过程。算力设施安全风险主要是 GPU 驱动^[16]和芯片漏洞^[17]问题。云平台安全风险主要是虚拟化^[18]和 Web 平台^[19]问题。

2.2.2 系统衍生风险

系统衍生风险是指那些与人工智能技术无直接关联,主要是技术系统外部因素造成因素的风险,包括不当使用、外部攻击和业务设计不完善等风险,相关风险可能对人身安全、社会安全甚至国家安全带来挑战。

(1) 不当使用安全风险。人脸识别技术能有效帮助执法部门维护社会治安,也能给人们的日常生活提供便利,而一些滥用、盗用、伪造个人生物特征的行为却给社会治安带来严重危害^[20-21]。2021 年央视 3.15 晚会曝光了科勒卫浴等知名品牌安装人脸识别摄像头,严重侵害了消费者隐私^[22]。

(2) 外部攻击安全风险。由于现实应用场景的开放性,人工智能系统面临对抗样本^[23-24]、模型窃取^[25-26]等恶意攻击,给人工智能安全性和可信赖性造成了威胁。2021 年,瑞莱智慧公司的研究人员在一项测试中,通过佩戴一副含有对抗样本图案的眼镜,破解了 19 款常见安卓手机的人脸识别解锁系统^[27]。

(3) 业务设计安全风险。主要指功能安全,包括预期功能安全,分为应用部署和运行维护

两个方面。在应用部署时,应充分考虑对周边环境的影响,防止危险故障的发生或在出现故障时能够有效控制,尽可能降低事故发生时造成的附带财产以及人员损失;在运行维护时,要求设备在设计时具有在人机交互层面对于安全隐患的考虑,全面识别受控设备中的所有危险。2018 年,美国亚马逊公司机器人误刺穿一罐驱熊喷剂,导致 24 名工人送医^[28]。

2.3 安全测评

安全测评主要包括数据安全测评、算法安全测评、基础设施安全测评、系统应用安全测评。

2.3.1 数据安全测评

数据安全的组织机构信息安全体系的重要环节,通过国家标准《数据安全能力成熟度模型》来评估机构数据安全能力,用组织的能力成熟度来进行安全风险评估。技术维度上看,对数据生存周期安全性进行测评,包括数据采集安全、数据传输安全、数据存储安全、数据处理安全、数据交换安全、数据销毁安全。管理维度上看,对组织的数据安全过程应具备安全能力的评估,包括组织建设、制度流程、技术工具、人员能力。通过以上两个维度的评估,我们能够发现组织数据安全能力短板,帮助组织机构快速查漏补缺,进而达到提升行业整体安全管理水平和产业竞争力的目的。

2.3.2 算法安全测评

算法安全是人工智能系统应用安全的核心要求,结合国内应用实践和标准编制组的研究成果,提出与国际标准接轨、适合我国国情的算法安全标准《机器学习算法安全评估规范》《信息技术人工智能机器学习模型及系统的质量要素和测试方法》《信息安全技术人脸比对模型安全技术规范》,提升机器学习算法实践应用的安全保障能力。

2.3.3 基础设施安全测评

基础设施安全是人工智能系统建立的根基保障,人工智能关键基础设施安全问题易被忽视,如学习框架自身代码实现、第三方图像处理库、算子库、GPU 驱动^[16]、芯片安全^[17]、虚拟化^[18]、web 平台^[19]、大数据^[29]等安全风险。可参考国际标准《深度学习软件框架评估方法》、国家标准《服务器安全技术要求和测评准则》、联盟标准《绿色计算服务器可信技术要求》,对学习框架和算力设施的安全稳定性评估,降低人工智能基础设施遭受的攻击风险。

2.3.4 系统应用安全测评

系统应用安全是人工智能安全最佳的实践验证,人工智能系统应用涉及多个行业和领域,覆盖多项技术协同实施,呈现多种智能产品服务形式。需针对技术、产品、服务和行业领域特点,依据法律法规、行业规范、标准指南进行符合性评估,依据产品设计文档对人工智能系统进行功能和预期功能适用范围、潜在受影响的人员数量、应对外部攻击能力、对结果依赖性和损害的不可逆转性等风险评估。

2.4 安全保障

人工智能安全保障体系中,政府发挥着领导性作用,企业发挥着决定性作用,政府和企业需共同努力在管理层和技术层保障人工智能系统的安全,管理层分为战略保障、企业保障和运营保障。

(1) 战略保障。战略体系主要包括法律法规、行业规范、标准指南,促使人工智能产业的安全发展,实现产业智能化升级的目标^[30]。我国在数据安全、算法安全、基础设施安全、应用安全方面的立法力度有所加大,配套法律法规的人工智能行业规范正在逐步跟上,对于自动驾驶、智慧金融、智能医疗等人工智能应用主要以主管部门的政策指导实施监管和规范。在《国

家新一代人工智能标准体系建设指南》的引领下,人工智能国际标准、国家标准、行业标准、团体标准等协调配套,在指南的指导下结合产业界实际情况,形成人工智能安全标准体系框架。



图2 人工智能安全标准体系框架

(2) 企业保障。企业保障体系主要包括组织设计、人员管理和流程管理。企业需要设立独立的人工智能安全管理部门,配备足量的专业管理人员,制定符合业务人员操作的人工智能安全要求,实现操作流程的及时更新。企业应具备专门的人员更迭管理团队,对关键岗位和对应业务人员的更迭情况有自动化、数字化的记录管理,对人员更迭中的异常情况进行实时监控,并进行追访回溯。企业还应具备对人工智能系统的监控、响应、升级处理与审核流程,建立完全独立的运营体系,实现运营数字化、自动化、实时化。

(3) 运营保障。运营体系的构建可以为人工智能系统的应用提供循环优化保障,通过事前风险评估、事中监测预警、事后安全审计,支撑安全运营全生命周期智能化发展。同时,建立贯穿高风险人工智能系统生命周期的风险管理系统,能够识别、分析和评估人工智能系统风险并采取相应的风险管理措施以降低风险。自动记录人工智能系统运行情况日志,日志应具备系统全生命周期的可追溯性以便于监测运行。一旦出现安全问题时,企业应对安全问题开展审计。

(4) 技术保障。技术内生安全是人工智能安全的核心要素,技术研发能保证技术内生的安全可靠。针对第二代人工智能技术存在的不可解释、鲁棒性差、不安全、不可信、不可靠、不

可扩展等缺陷,需通过技术手段检测和防御加固模型,研发关键核心技术和智能检测工具,以应对深度伪造^[31-32]、对抗样本^[23-24]、算法后门^[33-34]、数据劫持^[35-36]、框架缺陷等通用新型人工智能安全风险。

3 人工智能安全建议

我国人工智能发展正进入融合应用拓展深化的新阶段,对各类人工智能系统的安全测评充分反映出当前人工智能技术的安全应用仍存在非常大的风险。当前阶段,妥善评估并解决由人工智能引发的相关安全问题已经刻不容缓。下面就人工智能的安全问题及相关风险,提出几点建议。

(1) 加深国际治理探讨交流,制定适宜国情的监管政策。结合人工智能产业的发展特点,借鉴欧盟的监管思路,探索人工智能安全分类分级监管机制,构建人工智能监管组织架构,建立人工智能系统备案制度,遵循风险分级、最小干预原则,实现以安全促发展的目标^[37]。持续推进监管模式创新,通过“自监管+外部监管”的模式,构建多元主体协同合作的人工智能监管体系。

(2) 加快关键核心技术研发,统筹完善安全标准体系。技术研发和标准研制需同步推进,技术研发保证技术内生的安全可靠,标准研制规范技术应用的合规可控,二者相辅相成,密不可分^[38]。加强人工智能基础技术研究,包括小样本学习^[39]、迁移学习^[40]、联邦学习^[41]等。加快人工智能共性技术研究,包括高端智能芯片、深度学习框架、核心算法等。加速人工智能应用技术研究,包括多模态感知技术^[42]、人工智能与区块链融合技术、人工智能与量子信息交叉技术等。统筹规划人工智能安全标准体系,研制人工智能通用安全参考架构、人工智能开源框架、人工智能服务器、人工智能开发平台、人工智能安全标准以及人工智能安全评估指南。

针对已有标准完善智能安全要求,优先对其中较为迫切且应用较成熟,或应用较敏感的领域进行标准研究。

(3) 加强智能检测工具研发,建设精准监测预警平台。密切跟踪人工智能安全攻防、安全检测、内生安全^[43]等关键技术进展,研发智能产品和服务的可靠性、安全性等检测工具,推进人工智能安全测评平台落地推广,提升人工智能技术、产品和服务质量。面向智能语音、图像识别、智能机器人、自动驾驶、工业质检领域建设第三方试点测试平台并开展评估测评服务。面向人工智能产业发展,针对重点行业建立人工智能系统安全监测预警平台,确保人工智能系统安全且可靠。

(4) 加速检测认证能力建设,遴选一批权威测评机构。构建与国际接轨的人工智能检测认证体系,对高风险人工智能应用在投放市场前进行第三方符合性评估活动,以评估安全风险等级。建设安全标准计量、认证认可、检验检测、试验验证等产业技术示范应用平台,提升可对智能设备设计、开发、测试、运营全生命周期进行安全测评能力,发展专业检测认证机构。完善第三方测评机构审核流程,加强第三方测评机构准入机制,提升检验检测认证行业的检验检测认证水平。

4 结束语

人工智能技术在计算机视觉、语音识别、自然语言处理等方面已经取得了巨大进展,在自动驾驶、智慧金融、智能医疗等重点民生领域深入应用。然而,人工智能系统的安全性问题频发,人工智能产业健康发展亟需建设人工智能安全测评及保障体系。本文通过梳理人工智能安全框架,有效分析人工智能发展过程中的潜在风险和质量缺陷,以管理和技术手段保障人工智能可控、可靠、可信赖,对于规范人工智能安全应用、提升人工智能安全治理能力具有重要意义。

参考文献

- [1] 尤茜. 万山磅礴看主峰——习近平总书记掌舵领航网信事业发展纪实 [EB/OL]. (2022-03-21) [2022-06-16]. https://www.ccps.gov.cn/xtt/202203/t20220321_153369.shtml.
- [2] 方滨兴. 人工智能安全 [M]. 北京: 电子工业出版社, 2020.
- [3] 方滨兴, 时金桥, 王忠儒, 等. 人工智能赋能网络攻击的安全威胁及应对策略 [J]. 中国工程科学, 2021, 23 (3): 60-66.
- [4] 陈光宇, 杨欣昱, 梁娜, 等. 以人为本的人工智能工程伦理准则探析 [J]. 电子科技大学学报 (社科版), 2020, 22 (06): 32-38.
- [5] ISO/IEC TR 24028-2020 信息技术. 人工智能. 人工智能中的可信度概述 [S]. 瑞士日内瓦: 国际标准化组织 (IX-ISO), 2022.
- [6] HU Yupeng, KUANG Wenxin, QIN Zheng, et al. Artificial Intelligence Security: Threats and Countermeasures [J]. ACM Computing Surveys (CSUR), 2021.
- [7] Utsunomiya H, Kobayashi N, Yamamoto S. A Safety Knowledge Representation of the Automatic Driving System [J]. Procedia computer science, 2016, 96: 869-878.
- [8] Ferreira F G D C, Gandomi A H, Cardoso R T N. Artificial Intelligence Applied to Stock Market Trading: A Review [J]. IEEE Access, 2021, 9: 30898-30917.
- [9] Hamet P, Tremblay J. Artificial Intelligence in Medicine [J]. Metabolism, 2017, 69: S36-S40. Adadi A, Berrada M.
- [10] Adadi A, Berrada M. Peeking Inside the Black-Box: A Survey on Explainable Artificial Intelligence (XAI) [J]. IEEE access, 2018, 6: 52138-52160.
- [11] Carabantes M. Black-Box Artificial Intelligence: An Epistemological and Critical Analysis [J]. AI & society, 2020, 35 (2): 309-317.
- [12] 冯登国, 张敏, 李昊. 大数据安全与隐私保护 [J]. 计算机学报, 2014, 37 (01): 246-258.
- [13] 方滨兴, 贾焰, 李爱平, 等. 大数据隐私保护技术综述 [J]. 大数据, 2016, 2 (01): 1-18.
- [14] 古天龙, 李龙, 常亮, 等. 公平机器学习: 概念、分析与设计 [J]. 计算机学报, 2022, 45 (05): 1018-1051.
- [15] Sakhnini J, Karimipour H, Dehghantanha A, et al. AI and Security of Critical Infrastructure [M]// Handbook of Big Data Privacy. Springer, Cham, 2020: 7-36.
- [16] Sabbagh M, Fei Y, Kaeli D. A novel GPU overdrive fault attack [C]// 2020 57th ACM/IEEE Design Automation Conference (DAC). IEEE, 2020: 1-6.
- [17] Tan B, Elnaggar R, Fung J M, et al. Toward Hardware-Based IP Vulnerability Detection and Post-Deployment Patching in Systems-on-Chip [J]. IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems, 2020, 40 (6): 1158-1171.
- [18] AbdElRahem O, Bahaa-Eldin A M, Taha A. Virtualization Security: A survey [C]// 2016 11th International Conference on Computer Engineering & Systems (ICCES). IEEE, 2016: 32-40.
- [19] Bugliesi M, Calzavara S, Focardi R. Formal methods for web security [J]. Journal of Logical and Algebraic Methods in Programming, 2017, 87: 110-126.
- [20] 景晨凯, 宋涛, 庄雷, 等. 基于深度卷积神经网络的人脸识别技术综述 [J]. 计算机应用与软件, 2018, 35 (01): 223-231.
- [21] 郑方, 艾斯卡尔肉孜, 王仁宇, 等. 生物特征识别技术综述 [J]. 信息安全研究, 2016, 2 (01): 12-26.
- [22] 四川观察. 央视 315 曝光 | 多家知名商店安装人脸识别摄像头 [EB/OL]. (2021-03-15) [2022-06-16]. <https://baijiahao.baidu.com/s?id=1694301688869311671&wfr=spider&for=pc>.
- [23] 张思思, 左信, 刘建伟. 深度学习中的对抗样本问题 [J]. 计算机学报, 2019, 42 (08): 1886-1904.
- [24] Fan S. Research on Deep Learning Energy Consumption Prediction Based on Generating Confrontation Network [J]. IEEE Access, 2019, 7: 165143-165154.
- [25] TRAMÈR F, ZHANG F, JUELS A, et al. Stealing

- Machine Learning Models via Prediction APIs[C]//USENIX Association. In 25th USENIX Security Symposium, Berkeley, CA: USENIX Association, 2016: 601-618.
- [26] WANG B H, GONG N Z. Stealing Hyperparameters in Machine Learning[C]//In 2018 IEEE Symposium on Security and Privacy. 2018: 36-52.
- [27] 法人杂志. 瑞莱智慧: 聪明的防御专家 [EB/OL]. (2022-03-18) [2022-06-16]. <https://baijiahao.baidu.com/s?id=1727618095335507966&wfr=spider&for=pc>.
- [28] 孙欣祺. 机器人真的完美? 亚马逊美国仓库一自动化机器扎破防熊喷雾罐, 致 24 人入院. [EB/OL]. (2018-12-06) [2022-06-16]. <https://wenhui.whb.cn/third/baidu/201812/06/228844.html>.
- [29] 李学龙, 龚海刚. 大数据系统综述 [J]. 中国科学: 信息科学, 2015, 45 (01): 1-44.
- [30] 吴汉东. 人工智能时代的制度安排与法律规制 [J]. 法律科学 (西北政法学报), 2017, 35(05): 128-136. DOI:10.16290/j.cnki.1674-5205.2017.05.012.
- [31] Güera D, Delp E J. Deepfake Video Detection Using Recurrent Neural Networks[C]//IEEE. 2018 15th IEEE International Conference on Advanced Video and Signal Based Surveillance (AVSS). New York: IEEE, 2018: 1-6.
- [32] Lyu S. Deepfake Detection: Current Challenges and Next Steps[C]//IEEE. 2020 IEEE International Conference on Multimedia & Expo Workshops (ICMEW). New York: IEEE, 2020: 1-6.
- [33] Geigel A. Neural Network Trojan[J]. Journal of Computer Security, 2013, 21 (2): 191-232.
- [34] Dai J, Chen C, Li Y. A Backdoor Attack Against LSTM-Based Text Classification Systems[J]. IEEE Access, 2019, 7: 138872-138878.
- [35] Hartmann K, Steup C. Hacking the AI-the Next Generation of Hijacked Systems[C]//IEEE. 2020 12th International Conference on Cyber Conflict (CyCon). New York: IEEE, 2020, 1300: 327-349.
- [36] 任奎, 孟泉润, 闫守琨, 等. 人工智能模型数据泄露的攻击与防御研究综述 [J]. 网络与信息安全学报, 2021, 7 (01): 1-10.
- [37] 张琳琳, 王腾. 人工智能安全国际化进展研究 [J]. 信息通信技术与政策, 2021 (11): 73-78.
- [38] Wang Y X, Hebert M. Learning to Learn: Model Regression Networks for Easy Small Sample Learning[C]//ECVA. European Conference on Computer Vision. Berlin: Springer, 2016: 616-634.
- [39] Zhuang F, Qi Z, Duan K, et al. A Comprehensive Survey on Transfer Learning[J]. Proceedings of the IEEE, 2020, 109 (1): 43-76.
- [40] Yang Q, Liu Y, Chen T, et al. Federated machine learning: Concept and applications[J]. ACM Transactions on Intelligent Systems and Technology (TIST), 2019, 10 (2): 1-19.
- [41] 马茜, 谷峪, 张天成, 等. 一种基于数据质量的异构多源多模态感知数据获取方法 [J]. 计算机学报, 2013, 36 (10): 2120-2131.
- [42] 中兴通讯股份有限公司, 中国信息通信研究院, 奇安信科技集团股份有限公司, 等. 2030+ 网络内生安全愿景白皮书 [R]. 2021.