

总体国家安全观视域下人工智能安全风险治理研究

皮勇, 张明诚

(同济大学上海国际知识产权学院, 上海 200092)

摘要: 人工智能技术是引领中国社会智能化转型的核心技术, 人工智能安全是保障人工智能健康发展的关键。随着人工智能技术运用领域的广谱性扩散, 人工智能安全风险加剧蔓延, 严重危害总体国家安全。在当前情势下, 由战略政策、伦理规范、技术标准和法律法规组成的人工智能安全风险治理框架对总体国家安全的聚焦度不足, 各安全治理要素衔接不畅并存在安全保障缺口, 已不符合人工智能安全风险化解的内在逻辑, 无法满足充分保障总体国家安全的风险治理需要。人工智能安全风险治理应在总体国家安全观的指导下, 贯彻全面治理与系统治理思维, 通过对现有治理框架进行修正, 确立整体治理、动态治理、精准治理、差异治理原则并嵌入具体治理措施, 通过系统性化解安全风险全面保障人工智能安全与总体国家安全, 促进人工智能健康发展, 推动社会智能化转型。

关键词: 总体国家安全观; 人工智能安全; 风险治理; 算法; 数据

中图分类号: G322.0 **文献标识码:** A

Research on Artificial Intelligence Security Risk Governance Under the Overall National Security Concept

Pi Yong, Zhang Mingcheng

(Shanghai International College of Intellectual Property, Tongji University, Shanghai 200092, China)

Abstract: Artificial intelligence (AI) technology is the core technology that leads China's intelligent transformation, and AI security is the key to ensuring the healthy development of AI. With AI technology's widespread application, security risks have escalated and spread, seriously endangering overall national security. Currently, the AI security risk governance framework, consisting of strategic policies, moral standards, technical standards, and laws and regulations, lacks sufficient attention to overall national security. Various security governance elements are not well connected and have security gaps that no longer meet the internal logic of AI security risk resolution and cannot meet the risk governance needs of fully safeguarding overall national security. AI security risk governance should be guided by the overall national security concept, implement comprehensive and systematic governance ideas, revise the existing governance framework, establish the principles of overall governance, dynamic governance, precise governance, and differentiated governance, and embed specific governance measures. By systematically resolving security risks, AI security and overall national security can

基金项目: 国家社会科学基金重点项目“新发展理念与总体国家安全观视域下我国网络安全的刑法保障体系研究”(21AZD082), 教育部规划项目“新发展理念视域下人工智能安全发展的刑法保障研究”(21YJA820017)。

收稿日期: 2022-07-14

作者简介: 皮勇(1974—), 男, 湖北通城人, 博士、教授、博导, 研究方向为人工智能法学与刑法学。

通信作者: 张明诚

be fully protected, promoting AI's healthy development and driving society's intelligent transformation.

Key words: Overall national security concept; Artificial Intelligence (AI) security; Risk governance; Algorithm; Data

0 引言

自1956年麦卡锡、明斯基等科学家在达特茅斯会议首次提出人工智能概念以来,在近70年的发展历经三次浪潮,在算力、算法、数据的助力下,新一代人工智能开始走向大规模社会化运用。人工智能是通用性技术,正推动第四次工业革命^[1]。当下,人工智能已经深度嵌入社会生活,在各领域产生重大影响,推动产业创新与变革、促进国家经济发展和社会治理模式升级。与此同时,科技创新呈现出高度复杂性与不确定性,现有规则与制度被不断挑战,人类加速进入风险社会时代^[2]。人工智能并不完美,在技术运用中衍生出大量安全风险。随着人工智能全面影响经济各个产业发展^[3],产生于科技领域的人工智能安全风险逐渐向政治、军事乃至经济、文化等多领域蔓延,导致传统安全与非传统安全问题不断涌现,风险覆盖面与危害性显著提升,严重危害总体国家安全。习近平总书记强调,要加强人工智能发展的潜在风险研判和防范,维护人民利益和国家安全,确保人工智能安全、可靠、可控。系统性构建人工智能安全风险治理体系,应遵循从风险识别到风险化解的风险治理思路,满足维护总体国家安全的风险治理需要,在总体国家安全观的指导下解决并完善当前安全风险治理体系存在的问题与局限,切实保障中国人工智能安全与国家安全。

1 人工智能安全风险识别之检视

防范并化解潜在风险是人工智能安全风险治理的根本目标,人工智能安全风险只有被具象化并转换为具体运用领域中的安全问题,才能更好地被认知。因此,对人工智能运用具体领域中出现的风险种类与特征进行识别是针对性开展安全风险治理的前提。现有研究普遍结合风险产生场景,通过列举式方法对人工智能运用场景内的具体风险进行识别,但该种风险识别方式容易产生识别遗漏。因此,应转变风险识别思路,从人工智能技术不足与技术局限出发进行风险溯源,通过对人工智能安全风险进行类型化总结,实施源头治理,减少风险治理盲区。

1.1 人工智能安全风险识别的具象化反思

随着新一代人工智能在社会各领域的广泛运用,其技术不足与局限产生的负面效应逐渐显现,现有研究分别聚焦人工智能运用的不同领域,针对运用中产生的具体安全风险进行识别。学者观察到,在军事国防领域,人工智能军事化运用加剧了国际体系的不稳定性^[4];在交通领域,自动驾驶汽车频发交通事故并引发归责难题^[5];在医疗领域,医疗人工智能出现诊断和操作失误造成人员伤亡^[6];在家居领域,智能音箱播放暴恐内容并泄露用户信息^[7];在消费领域,经营者利用算法权力进行“大数据杀熟”损害消费者利益^[8];在金融领域,存在金融人工智能增加监管难度、引发金融风险等问题^[9]。新一代人工智能运用产生的系列安全风险不仅影响人工智能的健康发展,还在诸多运用领域引发了紧迫的安全问题,严重危害公民个人安全、社会安全与国家安全。

当前研究从人工智能运用的具体领域切入,结合对技术运用中涌现的风险现象的观察与归纳,通过列举式方法,对安全风险进行具象化识别,并根据具体风险造成的危害后果提出对应的治理方案。但是,从现象出发的风险具象化识别思路仅能做到对局部领域的部分风险进行识别,通过列举式方法容易遗漏人工智能运用中的具体风险,对应的风险治理措施缺乏全面性与系统性,极易产生安全保障缺口。有学者^[10]对列举式风险识别方式进行改良,通过对风险特征进行类型化总结,将人工智能安全风险概括为伦理风险、极化风险、异化风险、规制风险与责任风险。从风险特征出发的类型化识别方式能够在一定程度上填补列举式识别方式产生的识别缺漏,但从学者对风险类型的概括看,其仅关注人工智能投入社会使用之后引发的安全风险,没有关注人工智能研发过程中产生的安全风险,在风险识别的全面性上仍存在不足。从运用风险现象出发的列举式识别机制与从风险特点出发的类型化识别机制均在系统性和全面性方面存在不足。因此,应转变风险识别思路,从风险源头即当前人工智能技术不足与局限出发,以风险溯源思路结合对技术不足与局限

诱发风险特征的概括，对人工智能安全风险进行类型化溯源，以此全面识别当前人工智能研发及使用全阶段的安全风险。

1.2 人工智能安全风险识别的类型化溯源

人工智能安全风险由新技术发展运用引起，只有科学客观认识人工智能技术的特性，发现机器智能的不足和有限性，才能充分识别技术运用产生的安全风险，进而为构建风险治理体系夯实基础。因此，应回归人工智能技术本源层面，以人工智能技术不足与技术局限为风险识别的逻辑起点。当前，在深度学习算法的助力与数据、算力的加持下，中国进入新一代人工智能发展阶段。新一代人工智能以算法支撑，用数据赋能，“算法的演进推动了人工智能的运用，数据的爆炸式增长提供了‘肥沃’土壤”^[11]。作为新一代人工智能技术的核心，算法与数据层面的技术不足与局限是当前人工智能安全风险产生的深层次原因。算法层面，新一代人工智能算法具备自主学习能力，但算法的可解释性较弱，深层神经网络中蕴含着诸多隐藏层，至今为止人们仍未探明隐藏层的具体含义^[12]，加之人工智能算法通常基于概率决策，决策过程不同于人类的分析逻辑，这也加剧了算法的不可解释性。同时，算法模型存在的“鲁棒性问题”“过拟合问题”“泛化弱性问题”都弱化了算法的可靠性和稳定性，加剧了人工智能安全风险^[13]。数据层面，新一代人工智能存在数据依赖性和数据敏感性，一方面，数据质量和规模决定了人工智能模型的训练效果，优质的大数据样本是构建高质量模型的必要条件；另一方面，输入数据的改变会导致算法的参数权重发生变化，微小的训练数据调整便能引发模型输出结果的大幅度改变^[14]。新一代人工智能算法技术层面的“自主性”“不可解释性”“不稳定性”问题以及对数据的“依赖”和“敏感”给人工智能运用的可靠性、稳

定性与可控性带来基础性安全隐患。从风险的技术溯源视角出发，综合新一代人工智能研发和使用两大阶段，能够以失向与失范两大基本风险概括技术不足与局限诱发的风险类型。

人工智能失向是指人工智能失去正确的发展方向，通过深度学习，人工智能不断迭代优化，若不控制学习数据的选取范围，任由其野蛮生长，人工智能将极有可能偏离人类预期的设计轨道，甚至朝着损害人类利益的方向发展。人工智能失向基本风险涵盖失本与失新两类特别风险。人工智能发展应当以人为本，当人工智能技术研发偏离该原则时，可能导致人类的机器化、人类活动的纯数理逻辑化与人类社会的机器异化。同时，人工智能发展应当促进人类创新，人工智能通过对海量数据的挖掘和整理，能够发现人脑难以察觉的事物联系与规律，利用人工智能进行发现和创新的过程通常更为高效，一旦人类形成创新过程的机器依赖，自身便很有可能失去对未知领域的探索能力和创新能力。

人工智能失范是指人工智能发展过程偏离人类社会规范。新一代人工智能的广泛社会化运用不断冲击人类社会规范，带来失控、失权和失管三大特别风险。所谓失控是指人工智能运行脱离控制，从而出现损害个人、社会和国家利益的严重情形；所谓失权，是指人工智能的发展运用对个人合法权利产生不利影响，机器智能的形成依赖研发人员投入大量训练数据，而这些数据的不当获取、分析及使用将对个体财产、生命等重要权利造成严重威胁，当数据中包含着国家秘密等信息时，人工智能还会给公共安全与国家安全造成严重危害。所谓失管，是指由于人工智能的自主性特征，使其在部分领域和一定程度上实现自主行动，继而自主实施损害行为的情形。人工智能安全风险的类型化总结见表 1。

表 1 技术溯源下人工智能安全风险的类型化总结

人工智能安全风险类型					
基本风险	失向风险		失范风险		
特别风险	失本	失新	失控	失权	失管
风险阶段	人工智能研发阶段		人工智能使用阶段		
风险来源	算法层面：不可解释性、自主性、不稳定性 数据层面：数据依赖性、数据敏感性				

2 总体国家安全观对人工智能安全风险的治理要求

总体国家安全观以人民安全为宗旨,以政治安全为根本,以经济安全为基础,以军事、文化、社会安全为保障,以促进国际安全为依托,既重视传统安全,又重视非传统安全,构建集各领域安全为一体的国家安全体系^[15],搭建新时代国家安全理论与实践的宏观架构。科技安全是总体国家安全观框架内的重点,习近平总书记提出,核心技术是国家经济安全、国防安全和其他安全的根本保障^[16]。新一代人工智能技术的发展引发了链式突破反应,是新时期推动社会各领域向智能化转型的核心技术。因此,切实防范并化解人工智能安全风险、保障人工智能安全是维护总体国家安全的必然选择。总体国家安全观从哲学辩证法和系统思维的高度揭示当前国家安全工作的全面性与系统性^[17],人工智能安全风险治理需满足总体国家安全观的治理要求,将全面治理与系统治理思维融入安全风险防范与风险化解流程中。

2.1 以全面治理思维构建人工智能风险防范体系

总体国家安全观的总体性与全面性体现在其兼顾传统与非传统方面的安全问题,总体国家安全观是高级非传统国家安全观,从事实层面涵盖国家安全的方方面面内容^[18]。从中国《新一代人工智能发展规划》战略布局看,在中国智能化转型不断深化的进程中,人工智能将全面融入社会治理、产业发展、公众生活与国家安全保障中来,智能与实体的连接拓展了新一代人工智能的运用领域,同时技术不足与局限在安全层面产生的负面影响从科技领域向外扩散,危及总体国家安全。新一代人工智能运用产生的安全风险不仅威胁军事、政治等传统安全领域,而且在文化、信息等非传统安全领域诱发安全隐患。例如,传统安全方面,在军事安全领域,各国人工智能军备竞赛加剧了国家对抗,在系统失控风险下,全面智能化的军事系统存在着大规模故障的安全隐患^[19];在政治安全领域,算法战、意识战等新型战略对抗方式以更为隐蔽和更具破坏性的方式干扰国家内部政治事务并对现有政府的合法性进行破坏^[4]。非传统安全方面,在文化安全领域,算法推送引发“信息茧房”效应,文化入侵与文化荼毒将更加

精准和高效;在信息安全领域,新一代人工智能运用对海量信息的需求将陡然增加信息的非法获取、交易以及使用风险,危害个体权利、社会秩序和国家安全。新一代人工智能运用风险已经蔓延至各安全领域,无论是传统因素,还是非传统因素,所有影响和危害国家安全的因素,都是总体国家安全观应该关注和包纳的内容^[18],在复杂的安全形势下,人工智能安全风险防范应符合总体国家安全观的总体观要求,贯彻全面治理思维,不仅要重视防范传统安全领域风险,更要聚焦非传统安全领域的风险防范,构建覆盖全领域安全的人工智能安全风险防范体系。

2.2 以系统治理思维设置人工智能风险化解机制

总体国家安全观架构内,各安全要素相互影响、彼此联系,新一代人工智能运用产生的安全风险在各安全领域间不断流动,加剧了风险危害和治理难度。总体国家安全观强调国家安全工作的系统性与协调性^[20],各领域安全的联结性特征要求以系统治理思维设置人工智能安全风险化解机制,充分发挥安全治理要素功能,有效化解安全风险,提升治理效能。

贯彻系统治理思维,需要坚持风险事前预防、事中控制与事后处置的协调统一,打通各治理要素间的连接通道并充分统筹人工智能发展与安全。首先,应对人工智能安全风险进行系统性全流程治理,通过设立风险预防机制,将人工智能运用风险抵御在各领域之外;对于已经渗透进入运用领域的风险,应及时控制风险蔓延,阻遏风险在运用领域间的扩散,避免产生实际损害;当人工智能安全风险已经对各领域安全造成实际损害时,应及时处置危害事件避免损害扩大,同时建立责任机制并弥补受害人损失。其次,系统治理要求充分促进治理要素间的衔接流动。人工智能风险化解机制的设置需要与安全风险在运用领域间持续流动的现实状况相匹配,一旦各安全治理要素间的流动衔接通道被堵塞,风险化解机制的联动性与系统性将被破坏,无法有效应对安全风险的跨领域传导和流动。只有打通各治理要素间的衔接通路,才能避免风险治理的碎片化。最后,在系统治理思路下,应系统性看待发展与安全问题,统筹人工智能发展与安全。总体国家安全观既重视发展问题,又重视安全问题。以人工智能发展

推动安全保障能力提升是人工智能安全风险化解的因应之道，针对风险化解实施的限制性措施与消耗的治理成本会对人工智能发展产生抑制作用，因此风险化解机制的系统性设置必须考虑实现发展与安全之间的平衡，力求以合理适度的治理成本与发展限制实现高效的风险防控。

3 人工智能安全风险治理现状与路径反思

3.1 人工智能安全风险治理的逻辑框架

基于对当前新一代人工智能安全风险治理文件的文本分析与类型归纳，可以将其划分为战略政策、伦理道德规范、技术标准与法律法规四个层面。在众多治理文件中，选取各层面内对人工智能安全风险治理产生重要影响的代表性文件进

行内容提炼，归纳出人工智能安全风险治理的逻辑框架，相关分析内容见表 2。

战略政策构成当前人工智能安全风险治理的顶层架构，决定了伦理规范、技术标准以及法律法规的制定方向。《新一代人工智能发展规划》(简称《规划》)是指导中国人工智能发展的战略纲领，它要求“加快人工智能与经济、社会、国防深度融合”“以人工智能提升国防实力，保障和维护国家安全”，将人工智能安全上升到国家安全层面。围绕《规划》要求，中国制定了人工智能安全风险治理的伦理规范、技术标准与法律法规，从治理文件的具体内容看，战略政策与伦理规范文件主要以人工智能为治理对象实施整体治理，技术标准与法律法规文件更多地将视角聚焦于算法、数据等

表 2 人工智能安全风险治理文件分析

所属层级	实施时间	制定主体	文件	主要安全风险治理内容	治理对象
战略政策	2017 年 7 月	国务院	《新一代人工智能发展规划》	人工智能技术应支撑、保障国家安全	人工智能
战略政策	2017 年 12 月	工信部	《促进新一代人工智能产业发展三年行动计划(2018—2020 年)》	重点构建人工智能网络安全保障体系，形成人工智能安全防控体系	人工智能
伦理规范	2019 年 6 月	国家新一代人工智能治理专业委员会	《新一代人工智能治理原则》	发展负责任的人工智能，保证人工智能公平公正、安全可控并增进人类福祉	人工智能
伦理规范	2021 年 9 月	国家新一代人工智能治理专业委员会	《新一代人工智能伦理规范》	将伦理道德融入人工智能全生命周期，提出 6 项基本伦理要求和 18 项具体伦理要求	人工智能
伦理规范	2022 年 3 月	中共中央办公厅、国务院办公厅	《关于加强科技伦理治理的意见》	明确科技伦理原则，保障人工智能等敏感领域的科技伦理安全	人工智能
技术标准	2019 年 10 月	全国信息安全标准化技术委员会、大数据安全标准特别工作组	《人工智能安全标准化白皮书(2019 年版)》	提出各领域人工智能安全标准的建构原则和方向	人工智能
技术标准	2020 年 7 月	国家标准化管理委员会、中央网信办、国家发展改革委、科技部、工信部	《国家新一代人工智能标准体系建设指南》	明确了人工智能标准体系框架，对安全及伦理标准作出规定	人工智能
法律法规	2021 年 9 月	全国人大	《数据安全法》	规范数据处理活动，促进数据安全与发展	数据
法律法规	2021 年 11 月	全国人大	《个人信息保护法》	规范个人信息处理活动，明确个人信息处理规则，保障个人信息安全	数据
法律法规	2022 年 3 月	国家网信办、工信部、公安部、市场监督管理总局	《互联网信息服务算法推荐管理规定》	规范算法推荐服务，促进算法推荐公平、透明、合理，维护公民、社会、国家利益与安全	算法

具体安全领域实施局部治理。在战略政策的统领下，伦理规范、技术标准与法律法规之间彼此联系与影响，在安全治理要素间形成双向传导机制。详言之，在伦理规范与法律法规层面，法律法规源于伦理道德，伦理规范的变化推动法律法规内容的调整，法律法规又作用于伦理实现，为其附加强制力^[21]。在技术标准与法律法规层面，法律与标准不断融合，呈现出“你中有我，我中有你”的交叉联结特征^[22]。在伦理规范和技术标准层面，技术安全标准的制定需要满足伦理安全规范的基本要求，同时技术安全标准随技术发展不断变化，又推动了伦理规范内容的丰富与发展。人工智能安全风险治理在以战略政策为中心，伦理规范、技术标准、法律法规互相联动的宏观治理框架内，包括科技向善、多元共治、设立人工智能安全监管部门、开展系统性风险监测与评估等微观层面的具体治理原则、制度和措施被不断纳入，建构了从整体到局部、从宏观到微观的风险治理体系，如图1所示。




图1 人工智能安全风险治理的逻辑框架

3.2 人工智能安全风险治理的路径反思

人工智能安全风险在各安全领域内广泛扩散，风险危害性与复杂性显著增强。面对风险弥散化与威胁扩大化，以战略政策为核心的治理框架对总体国家安全的聚焦度存在一定不足，无法充分应对人工智能安全风险蔓延带来的安全冲击。与此同时，伦理规范、安全标准与法律法规间的传导机制并不通畅，无法充分发挥三者间的协调配合作用与协同治理功效。加之给予风险治理强制力保障的法律法规存在安全保障缺口，使当前人工智能安全风险治理体系缺乏全面性与系统性，

无法充分满足总体国家安全观的治理要求。

(1)战略政策对总体国家安全的聚焦度不足。为抢占人工智能发展高地，世界各国都在加快战略布局，加速人工智能运用落地，赋能经济发展与社会进步。人工智能战略政策是安全风险治理框架的核心部分，但当前战略政策主要聚焦于推动人工智能与实体经济的深度融合^[23]，对总体国家安全的保障存在不足。

一方面，当前战略政策对保障人工智能国家安全的整体性考量不足。世界各国与区域性组织在人工智能战略上有不同侧重，总体呈现出3条战略方向。①着重促进人工智能产业发展，推动数字化转型，形成人工智能创新优势，制定此类战略的国家有英国、日本等；②高度重视人工智能运用和技术局限带来的伦理问题，如欧盟；③重点关注人工智能运用对国家安全的影响，如美国^[23]。美国将人工智能安全视为国家安全战略的重要组成部分，认为人工智能是具有颠覆性的通用技术，将对国家安全产生变革性影响^[24]，通过发布《人工智能与国家安全》(Artificial Intelligence and National Security)、《2018年国防部人工智能战略摘要》(Summary of the 2018 Department of Defense artificial Intelligence Strategy)、《人工智能与国际安全》(Artificial Intelligence and International Security)等人工智能国家安全战略文件与报告，促进人工智能与国家安全深度融合。当前，中国人工智能战略政策缺乏指引人工智能国家安全建设的纲领性文件，虽有多部治理文件提及人工智能科技伦理与安全，但相关规定较零散，一定程度上缺乏对人工智能国家安全的整体性聚焦。

另一方面，当前战略政策在保障总体国家安全的全面性上存在一定不足。①战略政策对非传统领域国家安全的风险治理关注度不足，作为指导中国人工智能发展的战略纲领，《规划》将人工智能发展上升到国家重大战略层面，要求以人工智能提升国家竞争能力并保障国家安全。《规划》中有7处提及国家安全，但论述较为原则化，缺少对人工智能支撑国家安全的具体路径与制度设计，其重心是“以人工智能提升国防实力、保障和维护国家安全”。总体国家安全观不仅关注与国防能力紧密相关的军事、国土等传统安全领域，也重视经济、文化、科技等非传统安全领域。以提升国防

实力维护国家安全的规划路径仍是在传统安全视角下看待人工智能安全问题,对非传统领域国家安全的关注度存在一定不足。②《规划》着重强调人工智能对国家安全的助力作用,对人工智能安全风险给国家安全带来负面影响的聚焦度存在一定不足。人工智能不仅可以准确预测网络攻击、助力自主武器研发,提升国防能力^[12],对国家安全起到支撑和维护作用,技术运用产生的安全风险亦可能危害国家安全。例如,通过人工智能合成虚假的领导人讲话^[25],可能对国家安全造成严重危害。战略政策对总体国家安全聚焦度的不足使安全风险治理架构缺乏足够的全面性与系统性,无法充分保障总体国家安全。

(2) 伦理规范、技术标准与法律法规衔接不畅。伦理规范、技术标准和法律法规是人工智能安全风险治理框架的基本组成部分,各安全治理要素间形成的双向传导机制能够在感知外界风险变化时对治理框架下的具体治理措施做出整体性的修正调整以及及时化解外界风险带来的安全威胁。但是,目前伦理规范、技术标准和法律法规之间的衔接通路并不顺畅,导致治理体系无法有效应对风险变化。安全伦理规范与技术安全标准治理功效的充分发挥需要以法律法规的强制力予以保障。伦理道德通过对人的内心约束进而控制其行为^[26],因而人工智能安全伦理规范的落实依靠相关人员对规范的主动遵守。安全伦理规范通过对人工智能研发、使用、管理等多方主体行为进行约束,以达到风险控制目的,但研究证明在缺乏伦理强化机制的情况下,人工智能伦理准则在很多情况无法发挥效果^[27]。同时,在人工智能安全风险产生危害结果后,由于安全伦理规范普遍缺乏责任条款,无法依照规范内容追究相关主体责任,这将进一步削减研发、使用、管理等各方主体的责任意识,弱化伦理规范的内在约束力。技术标准作为软性法律,虽有实际效力但没有国家强制力予以保障^[28],仍存在上述问题。

为了使安全伦理规范与技术安全标准充分发挥风险治理功效,需要将规范内容转换为具有国家强制力保障实施的法律法规。但是,当前三者间的衔接转换通道未被充分打通,无法充分发挥安全风险的协同治理作用。在伦理规范与法律法规的衔接方面,《新一代人工智能治理原则》《新一

代人工智能伦理规范》均提出应加强人工智能风险监测与评估,但在法律法规层面并未对监测与评估的主体、方式、对象、责任等具体内容作出规定,导致治理措施无法有效落实。技术标准与法律法规的衔接问题体现在两个方面:①虽然技术标准已经制定,但在转换衔接过程中法律法规却不采纳对应标准,导致认定体系混乱。例如,《汽车数据安全若干规定(试行)》第九条将心律纳入生物识别信息范畴,并强调数据处理应符合强制性国家标准,但中国关于生物识别特征的国家标准中并没有包含这一信息^[29],这实质上扩大了汽车数据处理者的数据处理权利,容易诱发越权行为,产生侵权损害。②虽然法律法规存在规定,但对应标准缺失导致规定无法实际适用。以自动驾驶汽车为例,自动驾驶汽车产品质量缺陷在全球范围内诱发了多起交通事故。当前,已有法律规定了产品安全责任,如《刑法》规定了“生产、销售不符合安全标准的产品罪”,构成该罪的前提是生产的产品不符合该领域的“国家标准”“行业标准”。然而,自动驾驶各类安全标准处在不稳定的迭代完善过程中,在诸多技术层面仍缺乏统一安全标准,导致相关法律法规无法实际适用,使人工智能产品事故归责陷入困境。

(3) 法律法规存在安全保障缺口。由国家强制力保障实施的法律法规是化解人工智能安全风险,发挥治理功效的关键。然而,当前人工智能风险治理的法律法规存在安全保障缺口,无法全面化解人工智能在算法与数据层面的技术不足与局限产生的安全风险。在算法安全方面,法律法规仅对部分领域的算法运用风险进行了规制。2022年3月,中国施行《互联网信息服务算法推荐管理规定》,这是中国首部针对算法治理的法规。该规定对当前严重影响社会、经济秩序,侵犯公民权利的“大数据杀熟”“算法歧视”等问题进行回应,并规定不得通过算法屏蔽信息等方式干预信息呈现,这在一定程度上消解了由算法推荐造成的“信息茧房”效应,有效防范了人工智能运用可能引发的失权、失新风险。但是,当前算法规制体系缺乏全面性,算法运用早已嵌入社会生活的各个领域,当前法律法规仅针对算法推荐领域产生的安全风险进行了治理,在保障其他领域安全上存在滞后。同时,在保障算法稳定性与可靠性、避免算法运

用引发失控与失管风险以及规范算法设计、避免算法研发产生人工智能失本风险上,当前法律法规亦缺乏有效的风险规制措施。

针对人工智能发展中的数据安全风险治理,中国颁布《数据安全法》《个人信息保护法》《网络安全数据安全条例(征求意见稿)》等法律法规,从顶层设计、安全制度、权利义务、监管评估等多方面规范数据与信息处理活动。不过,上述法律法规在治理人工智能数据安全风险时仍缺乏全面性与系统性,无法规制人工智能数据数量匮乏或质量低下产生的安全风险。人工智能具有数据依赖性,可靠、可控、安全的人工智能模型需要以海量优质数据反复训练、不断迭代,若训练数据的收集、使用流程均具备合法性,但数据数量匮乏或质量低下,仍会导致人工智能运用缺乏可靠性和可控性。例如,训练医疗人工智能进行疾病诊断,需要向训练模型内输入大量病例资料,即便通过合法渠道收集病例资料并以合法使用方式用于合法目的,但如果某类疾病的相关数据资料匮乏,人工智能模型对此类疾病的识别将十分困难,从而造成误诊^[30]。打击针对数据本身的不当搜集、使用、交易等处理活动是当前《数据安全法》《个人信息保护法》等法律法规的重点规制内容,现有安全保障措施尚未聚焦人工智能“数据敏感性”与“数据依赖性”的技术局限与其衍生的安全风险,未能对人工智能模型研发、构建以及使用中的数据处理活动存在的安全风险进行有效规制。

4 人工智能安全风险治理体系的完善与建构

现有安全风险治理体系并未有效化解新一代人工智能运用引发的突出风险。人工智能安全风险治理应符合总体国家安全观的要求,贯彻全面治理与系统治理思维。在安全风险不断蔓延的情况下,应明确整体治理原则,确立总体国家安全观在人工智能安全风险治理体系中的核心位置,聚焦风险治理机制、治理体系对总体国家安全的保障作用,打通治理框架内各安全要素之间的连接通路,形成动态治理能力。同时,应统筹人工智能发展与安全,精准填补当前治理体系的安全保障缺口,在技术溯源的风险治理思路下,面向

人工智能算法、数据层面的技术不足与局限,针对风险种类与危害的不同实施差异治理,对当前治理体系进行系统性完善。

4.1 整体治理:总体国家安全观的全面嵌入

当前,由于战略政策层面对总体国家安全的聚焦不足,导致风险识别与风险治理缺乏全面性与系统性呈现出碎片化的治理格局。因此,应转变治理思路,确立总体国家安全观在人工智能安全风险治理体系中的核心位置,以总体国家安全观统筹整体安全风险治理并贯彻于人工智能安全风险治理的全过程。

贯彻整体治理原则对现有治理体系进行修正,从宏观层面看,应将总体国家安全观置于风险治理体系的核心,加强对人工智能国家安全的整体性考量,通过制定人工智能国家安全战略统筹伦理规范、技术标准与法律法规的内容制定,充分发挥安全风险治理措施对全领域安全的保障功能。总体国家安全观下,应着重发挥法律法规对治理措施落地的促进作用,参照《网络安全法》《数据安全法》维护保障国家安全的核心要义,制定《人工智能安全法》,为风险治理措施、机制与制度的实施提供全面、系统的强制力保障。从微观层面看,应在总体国家安全观指导下贯彻全面治理思维,通过坚持整体治理原则建立完整的风险事前预防、事中控制与事后处置机制,对人工智能研发、运用全过程进行风险治理,为人工智能产品研发、服务提供、日常管理以及使用等各环节提供安全保障。具体措施上,在风险的事前预防阶段,以严格的市场准入机制保障人工智能研发环节安全。投入市场的人工智能应用或产品必须符合技术安全标准和法律法规的强制性规定,同时设立安全负面清单,形成风险预警与市场退出机制,防范研发风险;在风险的事中控制阶段,应从风险识别出发,建立风险响应机制,快速识别风险类型,以风险化解为目标,明确人工智能应用与产品的提供者、管理者和使用者的安全保障义务,充分发挥个人、企业、政府的风险控制能力,形成多主体协同的风险控制体系。在风险的事后应对阶段,应避免风险蔓延,建立健全追责机制,对风险承受人进行积极救治和损害赔偿并制定、完善法律责任体系。

4.2 动态治理：打通安全治理要素间的衔接通道

在当前治理体系下，各安全治理要素间衔接不畅，无法充分应对风险样态的不断变化。因此，根据总体国家安全观的要求，应贯彻系统治理思维，践行动态治理原则，畅通伦理规范、技术标准与法律法规间的衔接通道，充分发挥各安全要素的治理效能。

一方面，应落实伦理规范、技术标准中的安全治理内容向法律法规的转换，以强制力保障治理方案实施。在伦理规范同法律法规的衔接方面，应在法律法规具体条文的制定过程中汲取伦理规范表述的内在精神，将人工智能增进福祉、安全可靠、透明无歧视等伦理原则内化为法律法规的具体条文规定。例如，《人工智能伦理规范》要求人工智能避免偏见歧视，加强算法与数据的伦理审查，便应在法律法规中针对性规定伦理审查主体、歧视行为、相关法律责任等具体条文，为风险治理措施附加强制力。在安全风险治理过程中，法律法规需要援引技术标准实现风险规制，打通衔接通道，一是需要加快标准制定，避免因标准阙如导致法律法规无法实际施行；二是在进行标准援引时，法律法规应参照已经较为成熟的人工智能国家和行业基础共性标准^[29]，避免标准虚置与援引混乱。另一方面，人工智能运用的内外环境不断变化，风险危害呈现动态化与多样化，而法律法规的制定通常滞后于技术变化，现有法律法规时常无法对新型技术产生的各类风险进行有效规制，搭建灵活的法律框架能够有效缓解人工智能安全风险的多变性与法律法规滞后性之间的矛盾。欧盟委员会发布的《人工智能法案》通过设置附录清单的方式，将AI系统、高危AI系统等法律需要援引的半开放性概念纳入附录内，并通过对附录不断更新形成对技术发展的动态适应能力^[31]。设置附录清单使法律框架具备可扩增性，能够及时对技术发展做出回应，对中国开展人工智能动态治理具有借鉴意义。

4.3 精准治理：安全漏洞的全面填补

在总体国家安全观的要求下，不仅应贯彻全面治理思路，充分填补安全保障漏洞，同时应实施风险系统治理，统筹人工智能发展与安全，坚持精准治理原则，提升治理效率。安全风险治理应准确面向人工智能算法与数据层面的技术不足

与局限，以人工智能基本风险与特别风险为治理对象，针对当前法律法规存在的安全保障缺口进行全面填补，在维护人民利益、保障国家安全的同时平衡人工智能发展与安全，减少安全治理对技术发展带来的制约。

安全风险治理的本质是对技术运用的限制，坚持精准治理，旨在合理控制技术限制范围与力度，在避免抑制人工智能技术发展的同时降低治理成本。从风险的精准化解到安全漏洞的全面填补，应从风险产生的技术源头出发，实现对新一代人工智能失本、失新、失控、失权、失管五大风险的精准聚焦。新一代人工智能五大安全风险是在算法与数据层面的技术局限作用于人工智能具体研发、运用领域中产生的。针对数据层面的安全风险规制，当前法律法规主要面向数据使用、交易等处理活动，对人工智能“数据依赖性”与“数据敏感性”的技术局限诱发的安全风险关注度不足；针对算法层面的安全风险规制，当前法律法规仅关注到人工智能算法应用局部领域产生的特别风险，缺乏对算法应用一般风险的规制。完善现有治理体系在法律法规层面的风险规制缺失，应以《人工智能安全法》统筹人工智能算法安全与数据安全治理，对技术运用做出限制性规定，规范技术使用目的、方式、场景、对象，从源头消除各类安全风险。同时，以法律法规为人工智能算法模型构建、数据处理活动等技术标准规范提供强制力保障，提升人工智能运用的安全性、稳定性与可靠性。最后，在总体国家安全观统筹发展与安全的思路下，法律法规不应对治理主体施加过重的治理义务。不同主体的风险治理能力不同，当风险发生并产生实际危害时，应结合当前技术发展现状、治理主体的义务履行状况以及治理主体的实际治理能力对治理责任进行综合判断，避免严苛责任抑制产业发展。

4.4 差异治理：安全风险的分级化解

在总体国家安全观的指导下，应系统性构建安全风险治理体系，高效化解安全风险。在治理方式上，应针对人工智能五大特别风险的不同特点选取对应的治理措施，实现差异治理。欧盟《人工智能法案》根据人工智能风险强度的不同，采取分级治理方式，将人工智能风险分为不可接受风险、高风险、有限风险、极小风险，对应采用禁

止使用、严格管控、履行透明义务、不干预等治理方式^[31]。从风险分级依据看，当人工智能运用会严重损害人类尊严、自由、平等、民主、法治等核心权益时，这类运用便应该被禁止；当人工智能运用对人员健康、安全和基本权利具有重大有害影响时，便应该符合进入市场的强制性要求并受到严格管控；当AI运用场景造成的权利侵害并不严重时，则需要保障用户的知情权和选择权^[32]。根据风险的危害程度进行分级治理能够显著提升治理效率、减少治理成本，促进人工智能发展与安全的平衡。在针对人工智能失本、失新风险治理方面，失本和失新风险将会动摇以人为本的基本理念与社会基础，严重侵犯人类社会的核心权益，这种失向的人工智能发展应当坚决制止。失控、失权、失管风险的具体生成领域不同，产生的危害也不同。例如，若失控风险产生于自动驾驶领域，则可能对公民的生命、财产造成极大侵害，而聊天机器人失控发布歧视性语言，则只涉及对公民的人格侮辱。因此，应建立风险评估机制，结合风险产生具体情景的差异，综合评估风险危害，分级化解安全风险。

5 结语

人工智能安全风险治理应遵循从风险识别到风险化解的安全治理逻辑，从新一代人工智能技术不足与局限出发，以技术溯源思路结合对风险的类型化概括，通过完善治理措施，对现有治理框架进行修正，形成人工智能安全风险治理的环形架构，全面、系统地化解人工智能安全风险，如图2所示。




图2 人工智能安全风险治理的环形架构

人工智能安全风险治理应以总体国家安全观为指导核心，贯彻全面治理与系统治理思维，通过明确整体治理、动态治理、精准治理和差异治理原则，实现人工智能安全风险的综合治理。安全风险治理需以整体治理思维全面填补安全漏洞、系统性设置风险化解机制，保障各领域安全以及总体国家安全，同时灵活适应风险的动态变化趋势，打通各安全治理要素间的连接通道，切断风险流动路径。此外，透彻理解人工智能技术不足与局限，立足技术基础，针对人工智能五大特别风险进行精准治理，平衡人工智能发展与安全，减少治理资源内耗，促进科技创新。最后，人工智能技术运用风险对个人、社会、国家皆产生安全威胁，实施差异治理，根据风险产生的具体领域和风险级别的不同选取对应的治理措施，在满足不同主体安全需求的同时提升风险治理效能。

参考文献：

[1] AGRAWAL A, GANS J, GOLDFARB A. Economic policy for artificial intelligence[J]. Innovation policy and the economy, 2019, 19 (1): 139-159.

[2] 乌尔里希·贝克. 风险社会[M]. 何博闻, 译. 南京: 译林出版社, 2004.

[3] 郭凯明. 人工智能发展、产业结构转型升级与劳动收入份额变动[J]. 管理世界, 2019, 35 (7): 60-77, 202-203.

[4] 阙天舒, 张纪腾. 人工智能时代背景下的国家安全治理: 应用范式、风险识别与路径选择[J]. 国际安全研究, 2020, 38 (1): 4-38, 157.

[5] 皮勇. 论自动驾驶汽车生产者的刑事责任[J]. 比较法研究, 2022 (1): 55-70.

[6] 皮勇. 论医疗人工智能的刑法问题[J]. 法律科学 (西北政法大学学报), 2021, 39 (1): 134-148.

[7] 王秀丽, 罗龙翔, 王兵. 智能音箱的使用风险及其社会治理启示[J]. 北京航空航天大学学报 (社会科学版), 2022, 35 (11): 102-108.

[8] 廖建凯. “大数据杀熟”法律规制的困境与出路——从消费者的权利保护到经营者算法权力治理[J]. 西南政法大学学报,

- 2020,22(1):70-82.
- [9] 邢会强. 人工智能时代的金融监管变革[J]. 探索与争鸣, 2018(10):21-23,141.
- [10] 马长山. 人工智能的社会风险及其法律规制[J]. 法律科学(西北政法大學學報), 2018,36(6):47-55.
- [11] 中国人工智能学会. 中国人工智能发展报告(2019—2020)[M]. 北京:机械工业出版社, 2020.
- [12] 方滨兴. 人工智能安全[M]. 北京:电子工业出版社, 2020.
- [13] 谭铁牛. 人工智能·用AI技术打造智能化未来[M]. 北京:中国科学技术出版社, 2019.
- [14] JAGIELSKI M, OPREA A, BIGGIO B, et al. Manipulating machine learning: poisoning attacks and countermeasures for regression learning[C]. 2018 IEEE Symposium on Security and Privacy (SP), 2018.
- [15] 中央政府门户网站. 中央国家安全委员会第一次会议召开, 习近平发表重要讲话[EB/OL]. (2014-04-15) [2022-03-12]. http://www.gov.cn/xinwen/2014-04/15/content_2659641.htm.
- [16] 中共中央党史和文献研究院. 习近平关于总体国家安全观论述摘编[M]. 北京:中央文献出版社, 2018.
- [17] 刘跃进. 论总体国家安全观的五个“总体”[J]. 人民论坛·学术前沿, 2014(11):14-20.
- [18] 刘跃进. 非传统的总体国家安全观[J]. 国际安全研究, 2014,32(6):3-25,151.
- [19] 文力浩, 龙坤. 人工智能给军事安全带来的机遇与挑战[J]. 信息安全与通信保密, 2021(5):18-26.
- [20] 郑旭涛. 总体国家安全观:新时代中国国家治理的重要指导思想[J]. 学习与探索, 2020(1):44-50,175.
- [21] 刘华. 法律与伦理的关系新论[J]. 政治与法律, 2002(3):2-6.
- [22] 柳经纬. 标准与法律的融合[J]. 政法论坛, 2016,34(6):18-29.
- [23] 中国信息通信研究院和人工智能与经济社会研究中心. 全球人工智能战略与政策观察(2020)——共筑合作新生态[R/OL]. (2020-12-29) [2022-03-12]. <http://www.caict.ac.cn/kxyj/qwfb/ztbg/202012/P020201229520426700957.pdf>.
- [24] ALLEN G, CHAN T. Artificial intelligence and national security[M]. Cambridge: Belfer Center for Science and International Affairs, 2017.
- [25] SUWAJANAKORN S, SEITZ S M, KEMELMACHER-SHLIZERMAN I. Synthesizing obama: learning lip sync from Audio[J]. ACM transactions on graphics (ToG), 2017,36(4):1-13.
- [26] 徐靖. 软法的道德维度——兼论道德软法化[J]. 法律科学(西北政法大學學報), 2011,29(1):31-41.
- [27] HAGENDORFF T. The ethics of AI ethics: an evaluation of guidelines[J]. Minds and machines, 2020,30(1):99-120.
- [28] 廖丽, 程虹. 法律与标准的契合模式研究: 基于硬法与软法的视角及中国实践[J]. 中国软科学, 2013(7):164-176.
- [29] 张欣. 我国人工智能技术标准的治理效能、路径反思与因应之道[J]. 中国法律评论, 2021(5):79-93.
- [30] 周吉银, 刘丹, 曾圣雅. 人工智能在医疗领域中应用的挑战与对策[J]. 中国医学伦理学, 2019,32(3):281-286.
- [31] European Commission. Proposal for a regulation of the European parliament and of the council laying down harmonised rules on artificial intelligence (artificial intelligence act) and amending certain union legislative acts[EB/OL]. (2021-04-21) [2022-11-20]. <https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=celex%3A52021PC0206>.
- [32] 王伟洁, 邓攀科, 吕志远. 欧盟2021年《人工智能法》研究[J]. 信息安全研究, 2022,8(2):117-121.

(责任编辑 申秋红)